

Rechnen mit Fehlern

Eine Ausarbeitung zum Vortrag
Proseminar Kombinatorik
Sommersemester 2026

Ayleen Peschke

ayleen.peschke@uni-bielefeld.de

7. Juli 2026

Inhaltsverzeichnis

1	Einleitung	1
2	Binäre Suche	3
3	Fehlerfortpflanzung	5
4	Kondition	6
5	Fehleranalyse	8
6	Newton-Verfahren	9
	Literatur	12

1 Einleitung

Diese Ausarbeitung beschäftigt sich mit der Fehlerrechnung und basiert auf [1].

Betrachtet man ein numerisches Berechnungsproblem, muss auch immer mit Fehlern gerechnet werden, die beispielsweise durch Rechenoperationen oder durch eine fehlerhafte Eingabe von Daten entstehen.

Es wird zwischen drei Arten von Fehlern unterschieden:

Datenfehler

Zu Beginn des Rechenverfahrens benötigt der Rechner Eingabedaten. Es lassen sich jedoch nicht alle Daten genau darstellen, da die Maschinenzahl nur begrenzt ist. Bei numerischen Problemen sind die Eingabedaten oft ungenau, zum Beispiel bei Messdaten, sodass statt dem eigentlichen Eingabewert x ein gestörter Eingabewert $\tilde{x}$ vorliegt. Durch einen fehlerhaften Eingabewert muss das Ergebnis auch fehlerhaft sein und auch wenn alle Rechnungen exakt durchgeführt werden, pflanzt sich der Fehler fort und kann sogar verstärkt werden.

Rundungsfehler

Da der Maschinenzahlbereich nur begrenzt ist müssen alle Zwischenergebnisse gerundet werden, wodurch der Fehler bei jeder Rundung größer wird.

Verfahrensfehler

Ein Algorithmus ist eine theoretisch unendlich lange Folge von Rechenoperationen, die gegen das gewünschte Ergebnis konvergiert. Diese Folge wird nach endlich vielen Schritten abgebrochen und nähert sich dem richtigen Ergebnis an, ist jedoch nie exakt. Der Fehler, der nach Abbruch dieses Näherungsverfahrens verbleibt heißt Verfahrensfehler.

In der Praxis gibt es außerdem den Modellfehler, der entsteht, wenn das mathematische Modell das zu lösende Problem nicht genau beschreibt. Dieser Fehler wird hier jedoch nicht betrachtet.

Desweiteren gibt es zwei Darstellungen von Fehlern:

Der absolute Fehler $\Delta x := |x - \tilde{x}|$ beschreibt die Abweichung des gestörten Werts zum eigentlichen Wert.

Der relative Fehler $\varepsilon := \frac{\Delta x}{x}$ beschreibt den Anteil des absoluten Fehlers am exakten Wert.

2 Binäre Suche

Um ein numerisches Berechnungsproblem zu lösen bietet sich die binäre Suche an, bei der man sich durch das halbieren der Intervallmitten der richtigen Lösung nähert.

Definition 2.1. Sei $f : \mathbb{R} \rightarrow \mathbb{R}$ eine monoton wachsende Funktion und sei $y \in \mathbb{R}$. Existieren die Schranken $L, U \in \mathbb{R}$ mit $f(L) \leq y \leq f(U)$, so lässt sich $f^{-1}(y)$ durch die binäre Suche berechnen:

Sei $m_i = \frac{l_i + u_i}{2}$ der Mittelpunkt des Intervalls $[l_i, u_i]$:

Gilt $f(m_i) < y$, setze $m_i = l_{i+1}$ und fahre mit dem Intervall $[l_{i+1}, u_i]$ fort und betrachte $f(m_{i+1})$.

Gilt $f(m_i) > y$, setze $m_i = u_{i+1}$ und fahre mit dem Intervall $[l_i, u_{i+1}]$ fort und betrachte $f(m_{i+1})$.

Für die Folge $(m_n)_{n \in \mathbb{N}}$ aller Mittelpunkte gilt $\lim_{n \rightarrow \infty} m_n = f^{-1}(y)$. Man muss die Funktion $f(x)$ nicht kennen, sondern diese nur auswerten können. Man sagt, f ist durch ein Orakel gegeben.

Beispiel 2.2. Wir versuchen mithilfe der binären Suche Quadratwurzeln zu berechnen. Dafür wählen wir $y = 3$, $f(x) = x^2$ und unsere Schranken mit $L = 1$ und $U = 2$, da $\sqrt{3} \in [1, 2]$:

$$1, 5^2 = 2, 25 \Rightarrow \sqrt{3} \in [1, 5, 2]$$

$$1, 75^2 = 3, 0625 \Rightarrow \sqrt{3} \in [1, 5, 1, 75]$$

$$1, 625^2 = 2, 640625 \Rightarrow \sqrt{3} \in [1, 625, 1, 75]$$

$$1, 6875^2 = 2, 84765625 \Rightarrow \sqrt{3} \in [1, 6875, 1, 75]$$

$$1, 7134375^2 = 2, 9541015625 \Rightarrow \sqrt{3} \in [1, 71875, 1, 75]$$

$$1, 734375^2 = 3, 008056640625 \Rightarrow \sqrt{3} \in [1, 71875, 1, 734375]$$

Es lässt sich leicht erkennen, dass die Intervallmitten gegen das exakte Ergebnis konvergieren, jedoch nur sehr langsam. Nach sechs Schritten kennen wir erst die erste Nachkommastelle. Wenn man das Verfahren an dieser Stelle abbrechen würde, wäre der Verfahrensfehler also sehr groß.

Definition 2.3. Sei $[l_i, u_i]$ das zu betrachtende Intervall und $m_i = \frac{l_i + u_i}{2}$ dessen Mittelpunkt in der i -ten Iteration. Es gilt $|m_i - \sqrt{3}| \leq \frac{1}{2} \cdot |u_i - l_i| = 2^{-i} |u_1 - l_1| = 2^{-i} |U - L|$. Diese Schranke wird a-priori-Schranke genannt.

Im Nachhinein lässt sich eine genauere Schranke angeben, zum Beispiel $|m_i - \sqrt{3}| = \frac{|m_i^2 - 3|}{m_i + \sqrt{3}} \leq \frac{|m_i^2 - 3|}{m_i + l_i}$. Diese Schranke nennt man a-posteriori-Schranke.

Algorithmus 2.4. *Eingabe:* Ein Orakel zur Berechnung einer monoton wachsenden Funktion $f : \mathbb{Z} \rightarrow \mathbb{R}$, $L, U \in \mathbb{Z}$ mit $L \leq U$, $y \in \mathbb{R}$ mit $y \geq f(L)$
Ausgabe: das maximale $n \in \{L, \dots, U\}$ mit $f(n) \leq y$

```

 $l \leftarrow L$ 
 $u \leftarrow U + 1$ 
while  $u > l + 1$  do
   $m \leftarrow \left\lfloor \frac{l + u}{2} \right\rfloor$ 
  if  $f(m) > y$  then  $u \leftarrow m$  else  $l \leftarrow m$ 
output  $l$ 

```

Satz 2.5. Der Algorithmus 2.4 arbeitet korrekt und terminiert nach $O(\log(U - L + 2))$ Iterationen.

Beweis. Es gilt jederzeit $L \leq l \leq u - 1 \leq U$ und $f(l) \leq y$, sowie $u > U$ und $f(u) > y$. Also liegt das korrekte Ergebnis immer in $\{l, \dots, u - 1\}$.

Außerdem gilt

$$\begin{aligned} \max \left\{ \left\lfloor \frac{l + u}{2} \right\rfloor - l - 1, u - \left\lfloor \frac{l + u}{2} \right\rfloor - 1 \right\} &\leq \max \left\{ \frac{l + u}{2} - l - 1, u - \frac{l + u - 1}{2} - 1 \right\} \\ &\leq \frac{u - l - 1}{2}, \end{aligned}$$

das heißt $u - l - 1$ wird mit jeder Iteration mindestens halbiert und die Laufzeit beträgt $O(\log(U - L + 2))$ Iterationen. $\square$

3 Fehlerfortpflanzung

Sind die Daten an einem bestimmten Zeitpunkt fehlerhaft, so pflanzen sich diese Fehler trotz exakter Rechnungen fort.

Lemma 3.1. Seien $x, y \in \mathbb{R} \setminus \{0\}$ und $\tilde{x}, \tilde{y} \in \mathbb{R}$ Näherungen mit $\varepsilon_x := \frac{x-\tilde{x}}{x}$ und $\varepsilon_y := \frac{y-\tilde{y}}{y}$. Dann gilt für $\varepsilon_\circ := \frac{x \circ y - (\tilde{x} \circ \tilde{y})}{x \circ y}$ mit $\varepsilon \in \{+, -, \cdot, /\}$:

$$\begin{aligned}\varepsilon_+ &= \varepsilon_x \cdot \frac{x}{x+y} + \varepsilon_y \cdot \frac{y}{x+y}, \\ \varepsilon_- &= \varepsilon_x \cdot \frac{x}{x-y} - \varepsilon_y \cdot \frac{y}{x-y}, \\ \varepsilon_\cdot &= \varepsilon_x + \varepsilon_y - \varepsilon_x \cdot \varepsilon_y, \\ \varepsilon_/ &= \frac{\varepsilon_x - \varepsilon_y}{1 - \varepsilon_y}\end{aligned}$$

Beweis. Es gilt $\varepsilon_x = \frac{x-\tilde{x}}{x} \Leftrightarrow \tilde{x} = x \cdot (1 - \varepsilon_x)$ und analog $\tilde{y} = y \cdot (1 - \varepsilon_y)$

$$\varepsilon_+ = \frac{x+y-(\tilde{x}+\tilde{y})}{x+y} = \frac{x+y-(1-\varepsilon_x)\cdot x-(1-\varepsilon_y)\cdot y}{x+y} = \varepsilon_x \cdot \frac{x}{x+y} + \varepsilon_y \cdot \frac{y}{x+y},$$

ε_- erfolgt analog,

$$\varepsilon_\cdot = \frac{x \cdot y - \tilde{x} \cdot \tilde{y}}{x \cdot y} = \frac{x \cdot y - (1-\varepsilon_x) \cdot x \cdot (1-\varepsilon_y) \cdot y}{x \cdot y} = 1 - (1 - \varepsilon_x) \cdot (1 - \varepsilon_y) = \varepsilon_x + \varepsilon_y - \varepsilon_x \cdot \varepsilon_y,$$

$$\varepsilon_/ = \frac{x/y - \tilde{x}/\tilde{y}}{x/y} = \frac{x/y - ((1-\varepsilon_x) \cdot x) / ((1-\varepsilon_y) \cdot y)}{x/y} = 1 - \frac{1-\varepsilon_x}{1-\varepsilon_y} = \frac{1-\varepsilon_y-1+\varepsilon_x}{1-\varepsilon_y} = \frac{\varepsilon_x - \varepsilon_y}{1-\varepsilon_y} \quad \square$$

Es lässt sich erkennen, dass sich die relativen Fehler während der Addition und Subtraktion stark verstärken, falls $|x \pm y|$ in Relation zu $|x|$ und $|y|$ sehr klein ist.

Die absoluten Fehler verstärken sich jedoch deutlicher während der Multiplikation oder Division. Eine Mischung aus Punkt- und Strichrechnung hat deshalb sehr starke Auswirkungen auf die Fehler.

4 Kondition

Wir haben gesehen, dass sich die Fehler durch Rechenoperationen fortpflanzen und sogar verstärken können. Nun betrachten wir, wie empfindlich die Ausgabe eines Berechnungsproblems auf Fehler reagiert.

Definition 4.1. Sei $P \subseteq D \times E$ ein numerisches Berechnungsproblem mit $D, E \subseteq \mathbb{R}$. Sei $d \in D$ eine Instanz von P mit $d \neq 0$.

Wir definieren die **(relative) Kondition** $k(d)$ von d als

$$\limsup_{\varepsilon \rightarrow 0} \left\{ \inf \left\{ \left| \frac{e - e'}{d - d'} \right| \mid e \in E, (d, e) \in P \right\} \mid d' \in D, e' \in E, (d', e') \in P, 0 < |d - d'| < \varepsilon \right\}$$

wobei wir hier die Konvention $\frac{0}{0} = 0$ verwenden.

Ist $k(d)$ die Kondition der Instanz $d \in D$, so ist die **(relative) Kondition** des Problems P

$$\sup\{k(d) \mid d \in D, d \neq 0\}.$$

Durch die Kondition wird der unvermeidbare Fehler beschrieben, der durch den Eingabefehler in der Ausgabe entsteht, genauer gesagt das maximale Verhältnis der Fehler, wobei davon ausgegangen wird, dass der Eingabefehler sehr klein ist.

Die relative Kondition bezieht sich auf den relativen Fehler und es lässt sich analog die absolute Kondition definieren:

Proposition 4.2. Sei $f : D \rightarrow E$ ein eindeutiges numerisches Berechnungsproblem mit $D, E \subseteq \mathbb{R}$, und sei $d \in D$ eine Instanz mit $d \neq 0$ und $f(d) \neq 0$. Dann ist ihre Kondition:

$$\frac{|d|}{|f(d)|} \cdot \limsup_{\varepsilon \rightarrow 0} \left\{ \frac{|f(d') - f(d)|}{|d' - d|} \mid d' \in D, 0 < |d' - d| < \varepsilon \right\}$$

Korollar 4.3. Sei $f : D \rightarrow E$ ein eindeutig numerisches Berechnungsproblem, wobei $D, E \subseteq \mathbb{R}$ und f differenzierbar sei. Dann ist die Kondition einer Instanz $d \in D$ mit $d \neq 0$ und $f(d) \neq 0$

$$k(d) = \frac{|f'(d)| \cdot |d|}{|f(d)|}$$

Damit ein Problem als gut konditioniert eingestuft werden kann muss gelten $k(d) = 1$.

- Beispiel 4.4.**
- Sei $f(x) = \sqrt{x}$. Dann ist die Kondition $k(d) = \frac{\frac{1}{2\sqrt{x}} \cdot x}{\sqrt{x}} = \frac{1}{2}$. Das heißt die Wurzelfunktion ist gut Konditioniert.
 - Sei $f(x) = x + a$ und es gilt $k(x) = |\frac{x}{x+a}|$. Ist $|x + a| < |x|$, so ist die Funktion schlecht konditioniert.
 - Sei $f(x) = a \cdot x$. Diese Funktion ist immer gut konditioniert, da $k(x) = \frac{|a \cdot x|}{|x|} = 1$

5 Fehleranalyse

Ein Algorithmus heißt numerisch stabil, wenn alle Rechenschritte gut konditioniert sind. Numerisch stabil ist, genau wie gut konditioniert, nicht exakt definiert.

Man unterscheidet zwischen zwei Fehleranalysen:

- **Vorwärtsanalyse:** Es wird untersucht, wie sich der relative Fehler im Laufe einer Rechnung entwickelt.
- **Rückwärtsanalyse:** Jedes Zwischenergebnis wird als exaktes Ergebnis gewertet und es wird abgeschätzt, wie groß die Eingangsdatenstörung dafür sein müsste.

Beispiel 5.1. • *Vorwärtsanalyse:* $x \oplus y = \text{rd}(x + y) = (x + y) \cdot (1 + \varepsilon)$
mit $|\varepsilon| \leq \text{eps}(F)$

- *Rückwärtsanalyse:* $x \oplus y = x \cdot (1 + \varepsilon) + y \cdot (1 + \varepsilon) = \tilde{x} + \tilde{y}$ mit $|\varepsilon| \leq \text{eps}(F)$

$\text{eps}(F)$ beschreibt hierbei den größtmöglichen Rundungsfehler der Maschine.

Kombiniert man die Rückwärtsanalyse mit der Kondition, so kann man eine Abschätzung für den Fehler erhalten.

Für das Beispiel der Binären Suche 2.4 lässt sich eine Fehlerschranke abschätzen. Für 1,734375 ist die korrekte Eingabe $1,734375^2 = 3,008056640625 = 3(1 + \varepsilon)$ mit $\varepsilon \leq 0,00269$. Da die Kondition nach Beispiel 4.4 $\frac{1}{2}$ beträgt, kann der Fehler durch $\frac{1}{2} \cdot 0,00269$ beschränkt werden.

6 Newton-Verfahren

Das Newton-Verfahren ist ein weiteres Näherungsverfahren, dass sich oft besser eignet als die Binäre Suche. Es wird die Nullstelle einer differenzierbaren Funktion $f : \mathbb{R} \rightarrow \mathbb{R}$ gesucht, wobei $f'(x) \neq 0$ gelten muss.

Wir beginnen mit einem „geratenen“ Startwert x_0 und setzen

$$x_{n+1} \leftarrow x_n - \frac{f(x_n)}{f'(x_n)}, \quad n = 0, 1, \dots$$

Wir wollen nun erneut $\sqrt{3}$ berechnen:

Beispiel 6.1. Um $\sqrt{3}$ zu berechnen, wähle $f(x) = x^2 - a$, wobei $a = 3$. Es gilt:

$$x_{n+1} \leftarrow x_n - \frac{x_n^2 - a}{2x_n} = \frac{1}{2} \cdot \left(x_n + \frac{a}{x_n} \right), \quad n = 0, 1, \dots$$

Wir starten mit $x_0 = 1$ und erhalten

$$x_1 = \frac{1}{2} \cdot \left(1 + \frac{3}{1} \right) = 2$$

$$x_2 = \frac{1}{2} \cdot \left(2 + \frac{3}{2} \right) = \frac{7}{4} = 1,75$$

$$x_3 = 1,732142857\dots$$

$$x_4 = 1,732050810\dots$$

Es lässt sich schnell erkennen, dass die Folge viel schneller gegen das korrekte Ergebnis konvergiert als bei der binären Suche in Beispiel 2.4.

Dieses Beispiel des Newton-Verfahrens wird babylonisches Wurzelziehen genannt.

Wir wollen nun betrachten, wie sich der Fehler entwickelt.

Definition 6.2. Sei $(x_n)_{n \in \mathbb{N}}$ eine konvergente Folge reeller Zahlen und $x^* := \lim_{n \rightarrow \infty} x_n$. Existiert eine Konstante $c < 1$ und ein $n_0 \in \mathbb{N}$, verringert sich der relative Fehler, so dass

$$|x_{n+1} - x^*| \leq c \cdot |x_n - x^*|$$

für alle $n \geq n_0$ gilt, so hat die Folge (mindestens) Konvergenzordnung 1. Sei $p > 1$. Existiert eine Konstante $c \in \mathbb{R}$, so dass

$$|x_{n+1} - x^*| \leq c \cdot |x_n - x^*|^p$$

für alle $n \in \mathbb{N}$ gilt, so hat die Folge (mindestens) Konvergenzordnung p .
Eine Folge konvergiert linear bzw. quadratisch, falls die Konvergenzordnung 1 bzw. 2 ist.

Beispiel 6.3. Die Folge in Beispiel 2.4 konvergiert linear mit $c = \frac{1}{2}$.
Beim babylonischen Wurzelziehen in Beispiel 6.1 handelt es sich um eine quadratische Konvergenz, das heißt der Fehler quadriert sich mit jedem Schritt.

Wir wollen nun zeigen, dass das babylonische Wurzelziehen die Konvergenzordnung 2 hat.

Satz 6.4. Sei $a \geq 1$ und $x_0 \geq 1$. Die Folge $(x_n)_{n \in \mathbb{N}}$ ist definiert durch $x_{n+1} = \frac{1}{2} \left(x_n + \frac{a}{x_n} \right)$ für $n = 0, 1, \dots$. Für diese Folge gilt:

- (a) $x_1 \geq x_2 \geq \dots \geq \sqrt{a}$
- (b) Die Folge x_n konvergiert quadratisch gegen $\lim_{n \rightarrow \infty} x_n = \sqrt{a}$. Genauer gilt für alle $n \geq 0$:

$$x_{n+1} - \sqrt{a} \leq \frac{1}{2}(x_n - \sqrt{a})^2$$

- (c) Für alle $n \geq 1$ gilt:

$$x_n - \sqrt{a} \leq x_n - \frac{a}{x_n} \leq 2(x_n - \sqrt{a})$$

Beweis. (a) Nach dem Satz vom arithmetischen und geometrischen Mittel gilt $\sqrt{xy} \leq \frac{x+y}{2}$. Daraus folgt

$$\sqrt{a} = \sqrt{x_n + \frac{a}{x_n}} \leq \frac{1}{2} \left(x_n + \frac{a}{x_n} \right) = x_{n+1}$$

Außerdem gilt für $n \geq 1$:

$$x_{n+1} - x_n = \frac{1}{2} \left(x_n + \frac{a}{x_n} \right) - x_n = \frac{x_n^2}{2x_n} + \frac{a}{2x_n} - \frac{2x_n^2}{2x_n} = \frac{1}{2x_n} (a - x_n^2) \leq 0,$$

da $\sqrt{a} \leq x_n$ äquivalent ist zu $a \leq x_n^2$. Daraus folgt $x_{n+1} \leq x_n$, woraus die Behauptung folgt.

(b) Für alle $n \geq 0$ ist:

$$x_{n+1} - \sqrt{a} = \frac{1}{2} \left(x_n + \frac{a}{x_n} \right) - \sqrt{a} = \frac{1}{2x_n} (x_n^2 + a - 2x_n\sqrt{a}).$$

Es gilt $\frac{1}{x_n}(x_n - \sqrt{a}) \leq 1$ und daraus folgt $x_{n+1} - \sqrt{a} \leq \frac{1}{2}(x_n - \sqrt{a})$ für $n \geq 1$. Damit ist $\lim_{n \rightarrow \infty} x_n = \sqrt{a}$ bewiesen, da sich der Fehler mit jedem Schritt mindestens halbiert. Aus $x_n \geq 1$ folgt die Behauptung.

(c) Für $n \in \mathbb{N}$ gilt:

$$x_n - \sqrt{a} \stackrel{(a)}{\leq} x_n - \frac{a}{x_n} = 2 \cdot x_n - 2 \cdot \left(\frac{1}{2} \cdot \left(x_n + \frac{a}{x_n} \right) \right) = 2x_n - 2x_{n+1} \stackrel{(a)}{\leq} 2(x_n - \sqrt{a})$$

□

Aus (c) kann man ein Abbruchkriterium formulieren. Sei $\varepsilon > 0$ die absolute Fehlerschranke, dann bricht man das Verfahren ab, sobald $x_n - \frac{a}{x_n} \leq \varepsilon$.

Nach (b) gilt: ist $|x_n - \sqrt{a}| \leq 1$, dann ist die Konvergenz besonders schnell.

Literatur

- [1] Stefan Hougardy und Jens Vygen. Algorithmische Mathematik. 2., korrigierte und erweiterte Auflage. Berlin: Springer Spektrum, 2018.